建材租赁业务
智能化解决方案

收发料提效 × 业务问答 Agent × 本地模型

CONTENTS

目录

01 项目背景与痛点

02 解决方案

03 技术方案

现状与两大痛点

客户材料员 → 发需求 → 业务经理 → 转内部群 → 生产经理·工人 → 报实发数 → 会计·录骤风 → 规则问题 → 老板

钢管、扣件、盘扣租给工地，高峰一天约 20 车；合同和单据全是扫描件，一共 57 页。

01 人工开票易出错

比如实发 **10,000 根** → 少打一个零 **1,000 根** → 收不回 **9,000 根**

02 老板天天得盯在站里

“最低租几天？”

“丢一根赔多少？”

“这单怎么算？”

→ 都得问老板

CONTENTS

目录

01

项目背景与痛点

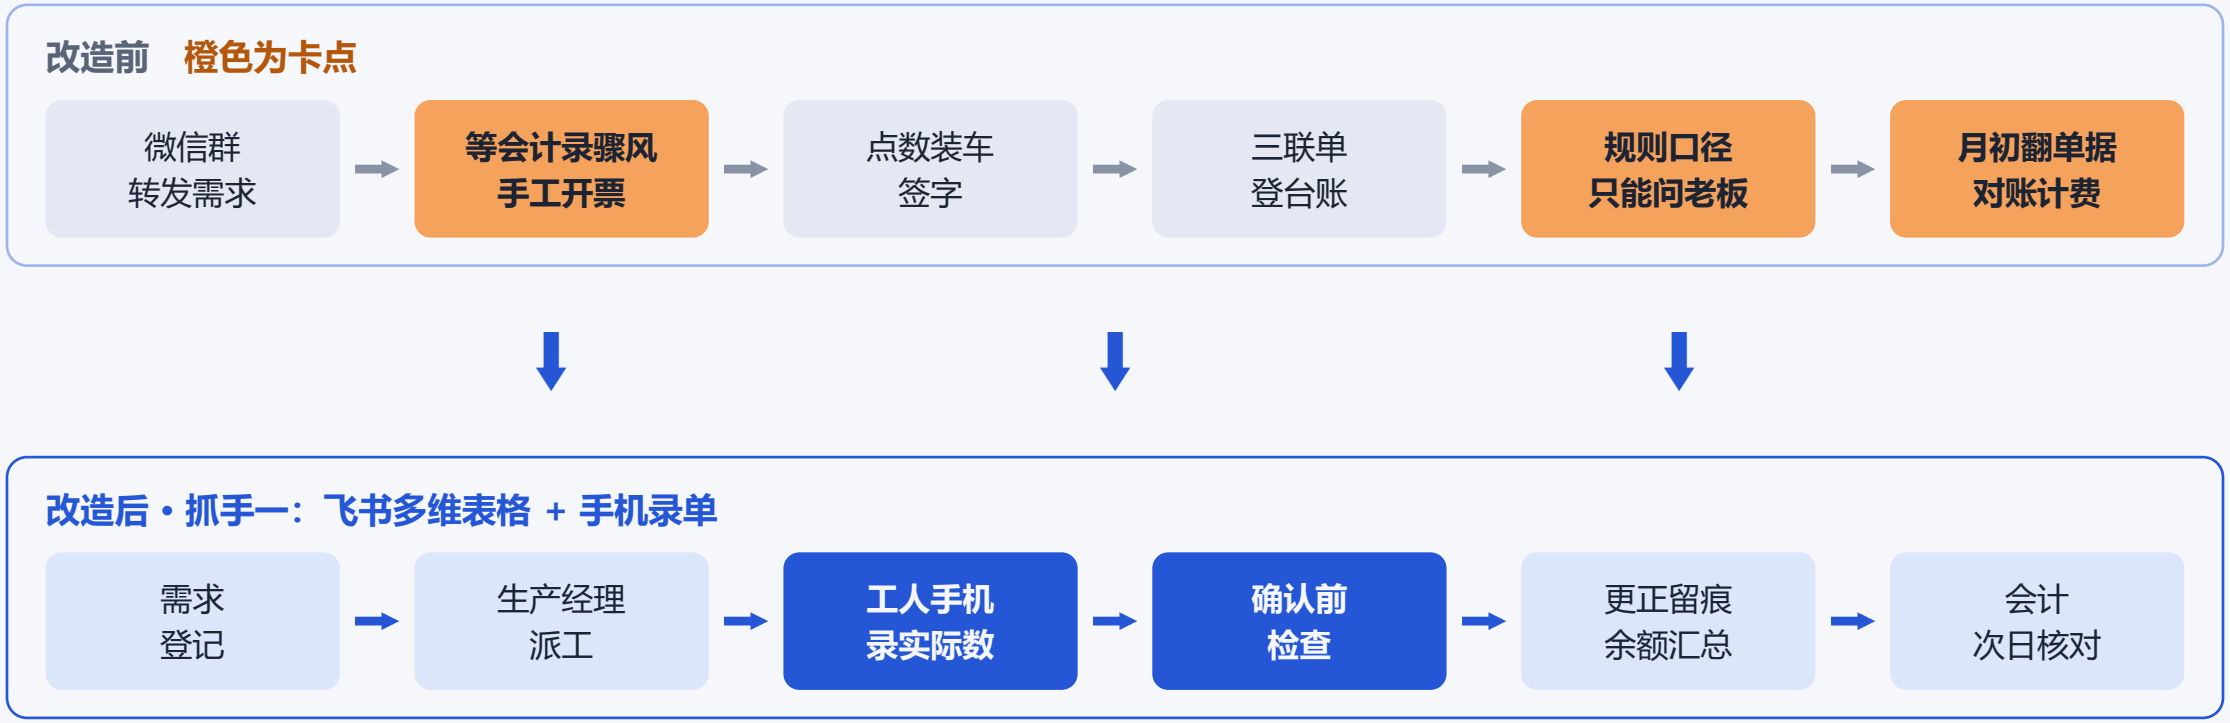
02

解决方案

03

技术方案

两个抓手：改造前 vs 改造后



抓手二：业务问答 Agent——规则、查数、计租在飞书里直接问，不再找老板。

抓手一：多维表格 + 手机录单

18 张业务表分 5 层，17 条自动化（12 条启用）

L5 结算对账	结算明细 197 条（真实 158 + 生成 39）· 月租草稿 · 计租试算
L4 业务执行	收发单主表 · 收发材料明细 · 项目材料余额
L3 需求管理	需求单 · 需求材料明细 · 需求流转记录
L2 合同参数	条款 · 租价 · 材料参数 · 验收费用 · 待确认事项
L1 基础档案	客户项目 · 租赁合同 · 材料档案

- ✓ 需求数和实际数分开记，不自动改平
- ✓ 合同拆成 5 张参数表；真实、试算、模拟数据分开放

手机录单 5 步

1. 选需求单，自动展开材料明细
2. 只填实际数量，需求数单独保留
3. 填齐自动提交，缺项发回执
4. 确认发料，在租余额自动更新
5. 录错发起更正，生成新单、原单保留

实际与需求差 >100 根/个 → 自动发飞书提醒

抓手二：业务问答 Agent 演示

类型	问题举例	怎么答
规则 · 带出处	钢管丢了怎么赔?	11 元/米、不含税，附合同原文
查数 · 追问	8 月底盘扣立杆还剩多少？那扣件呢?	查飞书表，自动沿用“8 月”
计算	100 根 6 米钢管 6/10 发、8/9 退，租金多少?	270 元，由计租函数算
跨合同对比	哪几份合同钢管丢失赔偿低于 12 元一米?	先写计划再查：三份 11 元/米
拒答	钢管轻度弯了收多少?	合同写“协商解决”，不编数字
飞书入口	手机上单聊直接问	先回“正在查”，默认只给结论

CONTENTS

目录

01

项目背景与痛点

怎么运转、卡在哪里

02

解决方案

两个抓手、流程与演示

03

技术方案

怎么做、为什么这样做

Agent 整体技术架构

业务应用层

- 手机录单（飞书多维表格）
- 业务问答 Agent（命令行 / 飞书单聊）
- 月结对账辅助（计划）

核心处理层

知识处理·离线

OCR 双路识别 → 算术+人工校对 → 按条款切块 → 类型标签+前缀 → bge-m3 向量化 → ChromaDB 入库

RAG 检索·在线

按合同过滤 → 关键词+语义 → 三路分路检索 → 条款类型过滤 → bge 重排 → **带出处原文**

Agent 编排

定合同 → 理解问题 → 早拒答 → 取证据/规划 → 组织回答 → 代码校验

工具与模型

- 14 个只读工具
- 计租·违约金函数
- 参数卡 + 关系网
- 豆包 lite ⇄ 本地 Qwen3.5

数据层

- ChromaDB · 134 块
- 飞书表 · 158 条真实明细
- 关系网 · 305 节点
- 原件 57 页（只读）

安全与运维

- 按合同隔离
- 只读应用+白名单
- 数字/参数溯源
- 模型可本地运行
- 轨迹日志
- 真实/试算分表

分层技术选型

层次	组件	选型	为什么这样选
数据	OCR	豆包视觉模型 + 本地 RapidOCR	手写数字认错时置信度仍有 0.97，必须双路交叉
数据	收发明细	飞书多维表格	录单流程已在飞书；查数走只读工具，不进向量库
检索	向量与重排	本地 bge-m3 + bge-reranker + ChromaDB	合同不出本机；按合同过滤、增量删写
检索	关系网	代码搭建（305 节点）	每条边能指回条款；不用 GraphRAG、图数据库
生成	云端模型	豆包 Seed-2.1-lite	三方案对比 92 / 86 / 87，每题约 0.0034 元
生成	本地模型	Ollama + Qwen3.5-4B（Q4 量化）	片段不出本机、API 费用 0；按环节逐个替换
计算	计租	计租 + 违约金函数	不让模型算数；回放真实结算单 157/158
编排	Agent 流程	六步工作流 + 有边界规划	红线代码兜底；复合题最多 8 步
入口	飞书机器人	专用只读应用 + 长连接	只开 3 项权限；本机连飞书，不需公网地址

数据与检索：从扫描件到带出处的答案

OCR 识别与校对

坑：手写“3.2”认成“3.Z”，置信度却有 0.97

- 视觉大模型 + 本地 OCR 两路比对
- 数量 × 天数 × 单价 = 金额，逐行核对
- 1,413 处改动全部留痕

158 条

真实明细与原件三个月总账一致

按合同结构切块

坑：整张表放一块，模型容易看错行

- 正文按条/款切，表格一行一块
- 老板确认的口径一条一块
- 本地 bge-m3 向量化，存 ChromaDB

134 块

每块都能引用到第几页第几条

给证据“上身份”

坑：问“钢管丢了怎么赔”，命中“裁截每口赔 10 元”

- 18 类条款类型标签 + 上下文前缀
- 关键词 + 语义两路，分三路取
- 本地 bge-reranker 重排

17/17

规则题主依据进前 3，串合同 0

Agent：六步循环 + 14 个只读工具

定合同 代码 → **理解问题** 模型 → **早拒答** 代码 → **取证据** 参数卡/检索/工具 → **组织回答** 模型 → **校验** 代码

14 个只读工具

查数 4	查在租、月结金额、收发记录、万能查询
计算 5	租金、丢失赔偿、整理费、违约金、合计
规则 2	查合同参数、查合同条款
关系网 3	跨合同对比、查关系、合同概览

提示词与记忆

- 提示词不写价格和规则，只写角色、红线、格式
- 理解问题温度 0，JSON 校验，没把握就反问
- 合同、月份由代码记住，只留最近 3 轮
- 复合题先写计划，最多调 8 次工具

Harness：系统强制执行

- 合同由代码定，不让模型选
- 数字和引文由代码校验
- 工具只读
- 复合题最多调 8 次工具
- 每次调用都记录轨迹

本地模型部署：Ollama + Qwen3.5

部署配置

运行方式	Ollama v0.40.13，装在本机
模型	qwen3.5:4b，Q4_K_M 量化
上下文	24K token，15,330 token 长输入不截断
硬件	RTX 4080 Laptop 12GB，100% 跑在 GPU
速度	生成约 98 token/秒
费用	API 费用 0（电费、硬件另计）

按环节切换，改配置不改代码

理解问题：豆包 ⇄ 本地	**工具调用·规划**：豆包 ⇄ 本地
组织回答：豆包 ⇄ 本地	**对题判断**：豆包 ⇄ 本地

接入后，发给云端的请求改动前后 24/24 逐字相同

替换要先过准入规则

同一套题 → 四项硬门槛一票否决 → 同题配对净差 ≥ 3 判退化 → 再比速度和费用

① 部署接入 ✓ | ② 抽样通过 ✓ | ③ 全量评测

回答发出前，代码逐条核对来源

答案发出去之前，代码会再核对一遍数字和引文的来源。

代码校验

- 引文须逐字出现在所引块，且块属于当前合同
- 结论里的数字须来自所引块、工具返回或用户原话
- 计算参数须来自用户原话或已有查数结果，被拦的调用不算证据
- 不通过 → 重写一次 → 仍不过降级“需人工确认”

演示：把 7406 写成“约 7400” → 找不到来源 → 被拦下

红线 bug 与对抗审查

“8月15日”曾被当成合同“20240815-汴商”，改为原文点名才切换，用错合同 **6 次 → 0 次**。四路对抗审查确认 30 条问题（红线级 4 条），全部已修。

135/135
47 道模拟题 × 3 次

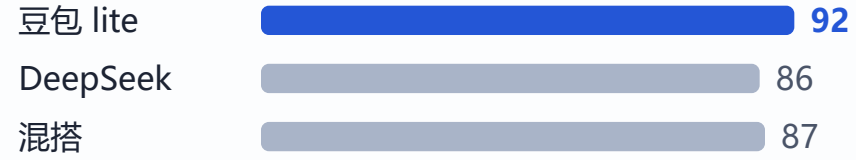
15/15 • 0
应拒答 · 用错合同

95%+
稳健性：换说法、多轮追问

99% • 98%
结构化输出 · 工具调用

按售前老师 17 项评价表建了测评体系，每次改动过了准入规则才替换

选型：35 题三方案对比（/99，10/20）



项目难点与解决方案

难点	问题	解决方案	效果
OCR 错了还很自信	手写“3.2”认成“3.Z”，置信度 0.97	视觉模型 + 本地 OCR 双路比对，算术自洽检查，人工校对留痕	158 条明细与原件三个月总账一致
命中相邻条款	“钢管丢了怎么赔”命中“裁截每口赔 10 元”	18 类条款类型标签 + 合同参数卡 + 上下文前缀 + 重排	主依据前 3 命中 16/17 → 17/17
跨合同复合题	“哪几份合同钢管丢失赔偿低于 12 元”，固定流程答不了	有边界规划：先写计划，只读工具最多调 8 次；参数须有来源	复合题 9/36 → 35/36
计算不能交给模型	最低 90 天按批补足等口径复杂，模型易算错	计租函数用代码计算，模型只负责转述	回放 158 条真实结算单 157/158 一致
业务口径冲突	老板口头答复与结算单有 3 处不一致	以实际收过钱的结算单为准，原答复保留并注明被取代	第三次确认“按结算单口径”，冲突关闭